

UrbanSmartSound: Un'Indagine Metodologica sulla Classificazione di Suoni Urbani mediante Architetture Ibride e Augmentation Avanzata

Luca Borrelli

559443

Mirko Abballe

566829

Corso di "Artificial Intelligence from Engineering to Arts"

Università degli Studi di Roma Tre

<https://github.com/lukebo01/urbanSmartSound>

14 agosto 2025

Sommario

Le città moderne sono ecosistemi complessi, definiti non solo dalla loro topografia visiva ma anche dal loro paesaggio sonoro. Questo articolo presenta UrbanSmartSound, un'indagine sistematica sulla classificazione di suoni urbani attraverso il deep learning. Il nostro obiettivo è sviluppare un classificatore robusto per 10 classi di suoni del dataset UrbanSound8K, affrontando le sfide del rumore di fondo e della variabilità dei dispositivi di registrazione. Il nostro percorso metodologico inizia con un'analisi comparativa di tre pipeline parallele, basate su diverse filosofie di feature extraction: spettrogrammi Log-Mel, coefficienti MFCC e feature acustiche ingegnerizzate. I risultati di questa prima fase hanno guidato lo sviluppo di un'architettura ibrida avanzata, che integra una Rete Neurale Convolutionale (CNN) 2D con una Rete Neurale Ricorrente (GRU) bidirezionale. Dimostriamo come l'arricchimento dell'input con feature dinamiche (Delta e Delta-Delta MFCC), l'ottimizzazione tramite Focal Loss e l'impiego della tecnica di data augmentation SpecAugment siano stati determinanti per il successo del modello. Il nostro classificatore finale raggiunge un'accuracy dell'87.0%, dimostrandosi efficace e ben bilanciato. Infine, un'analisi critica di architetture ensemble One-vs-Rest rivela la superiorità concettuale e prestazionale del modello multiclasse end-to-end, il quale apprende in un contesto competitivo essenziale per discriminare tra classi acusticamente simili.

1 Introduzione

L'ambiente urbano è un'intricata sinfonia di suoni. Dal ronzio costante del traffico al lamento di una sirena, ogni evento acustico contribuisce a definire il paesaggio sonoro (*soundscape*) di una città. Con l'avvento delle Smart Cities e dei sistemi autonomi, emerge la neces-

sità di dotare le macchine di una capacità di "ascolto" e interpretazione. La Classificazione di Suoni Urbani (USC) si pone come disciplina chiave, con un potenziale trasformativo per numerosi domini.

Un esempio emblematico è la guida autonoma. Come sottolineato da Walden et al., la percezione uditiva è complementare ai sensori visivi, in quanto non è ostruita dalla linea di vista [7]. La capacità di un veicolo di riconoscere istantaneamente la sirena di un mezzo di soccorso, anche se non visibile, è fondamentale per una navigazione sicura. Analogamente, sistemi di sorveglianza intelligenti possono aumentare la sicurezza pubblica rilevando automaticamente suoni anomali come spari. La sfida, tuttavia, è immensa: i suoni urbani sono spesso mascherati da rumore di fondo, distorti e registrati da microfoni di qualità variabile.

Il progetto **UrbanSmartSound** nasce per affrontare queste problematiche attraverso un percorso di ricerca metodologico. Il nostro lavoro non si limita all'implementazione di una singola architettura, ma inizia con un'esplorazione sistematica di tre pipeline sperimentali, ciascuna incarnante una diversa filosofia di rappresentazione del segnale:

1. **Pipeline A (Log-Mel):** Un approccio *data-driven* che tratta lo spettrogramma Log-Mel come un'immagine.
2. **Pipeline B (MFCC):** Un'evoluzione che utilizza una rappresentazione più compatta e decorrelata del segnale.
3. **Pipeline C (Engineered):** Un approccio basato sull'ingegnerizzazione manuale di feature acustiche.

L'analisi comparativa di queste pipeline ci ha permesso di validare l'ipotesi che le rappresentazioni ricche e apprese automaticamente fossero superiori. Abbiamo quindi focalizzato gli sforzi sull'evoluzione della

pipeline più promettente, la B, trasformandola in un modello avanzato ibrido CNN-GRU. Questo modello è stato potenziato con feature dinamiche, una funzione di costo specializzata (Focal Loss) e tecniche di data augmentation allo stato dell'arte. Infine, abbiamo messo in discussione l'assunto che un singolo modello "generalista" fosse la soluzione ottimale, confrontandolo con un "comitato di specialisti" (ensemble One-vs-Rest), traendo conclusioni sull'importanza dell'apprendimento competitivo.

2 Metodologia

La nostra metodologia è strutturata per essere iterativa e comparativa, partendo da un'attenta preparazione dei dati fino all'esplorazione di architetture complesse.

2.1 Dataset UrbanSound8K

Il fondamento del nostro lavoro è il dataset pubblico **UrbanSound8K** [5]. Esso consiste di 8732 clip audio etichettate, di durata massima di 4 secondi, suddivise in 10 classi: `air_conditioner`, `car_horn`, `children_playing`, `dog_bark`, `drilling`, `engine_idling`, `gun_shot`, `jackhammer`, `siren`, `street_music`. Una caratteristica fondamentale del dataset è la sua eterogeneità, con registrazioni a diversi sample-rate e bit-depth, che riflette la varietà del mondo reale. Altrettanto importante è la sua suddivisione predefinita in 10-fold, progettata per garantire esperimenti riproducibili e prevenire il data leakage tra training e test.

2.2 Pre-processing e Data Augmentation

Una pipeline di pre-processing rigorosa è stata applicata a ogni file audio.

2.2.1 Fasi di Pre-processing

- **Conversione a Mono:** Per ridurre la complessità computazionale senza una perdita significativa di informazione discriminante.
- **Ricampionamento a 22.050 Hz:** Un compromesso standard tra qualità del segnale e onere computazionale, sufficiente per rappresentare frequenze fino a 11 kHz.
- **Rimozione dei Silenzi (Trimming):** Per aumentare la densità informativa del segnale, assicurando che il modello si concentri sulle porzioni acusticamente rilevanti.
- **Normalizzazione dell'Ampiezza:** Per rendere il modello insensibile alle variazioni di volume di registrazione.
- **Standardizzazione della Durata a 4s:** Per garantire input di dimensione fissa, requisito fondamentale per le reti neurali.

2.2.2 Strategie di Data Augmentation

Abbiamo impiegato due strategie complementari di augmentation.

Oversampling Mirato (Offline): In fase di pre-processing, abbiamo identificato le classi minoritarie, `car_horn` e `gun_shot`, e applicato un oversampling mirato per bilanciare il dataset. Per ogni campione di queste classi, sono state generate nuove versioni applicando combinazioni casuali di *pitch shifting*, *time stretching* e aggiunta di rumore bianco. Questa operazione, eseguita una tantum, ha garantito che i dati aumentati rimanessero confinati nel fold del campione originale.

SpecAugment (Online): Integrato come primo layer del modello, SpecAugment [4] applica, solo in fase di training, mascheramenti casuali direttamente sull'input tempo-frequenza. Questa tecnica, come dimostrato da Arnault et al. [1], è estremamente efficace nel migliorare la generalizzazione. Le maschere applicate sono:

- **Frequency Masking:** Azzerava una banda orizzontale di coefficienti, costringendo il modello a non fare affidamento su specifiche bande di frequenza.
- **Time Masking:** Azzerava una banda verticale di timestep, rendendo il modello più robusto a occlusioni temporali.

2.3 Feature Extraction: Dal Segnale all'Immagine

Per rendere i dati audio processabili da architetture basate su convoluzioni, progettate per operare su dati a griglia come le immagini, è necessario trasformare il segnale audio monodimensionale (ampiezza vs. tempo) in una rappresentazione bidimensionale tempo-frequenza. Questo processo è fondamentale, poiché la scelta della rappresentazione influenza direttamente la capacità del modello di estrarre feature discriminanti.

2.3.1 Spettrogrammi Log-Mel

Il primo passo per ottenere una rappresentazione tempo-frequenza è calcolare uno spettrogramma tramite la Short-Time Fourier Transform (STFT), che scompone il segnale in finestre temporali sovrapposte e calcola lo spettro di frequenza per ciascuna. Tuttavia, un semplice spettrogramma con una scala di frequenze lineare non riflette la percezione uditiva umana: l'orecchio umano è molto più sensibile alle variazioni nelle basse frequenze rispetto a quelle nelle alte frequenze. Per questo motivo, abbiamo adottato la scala Mel, una scala percettiva che mappa le frequenze lineari (f) in una scala che approssima la risposta dell'orecchio umano, come descritto dalla formula:

$$m = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (1)$$

Questa rappresentazione è stata l'input per la nostra Pipeline A.

2.3.2 Mel-Frequency Cepstral Coefficients (MFCC)

Sebbene lo spettrogramma Log-Mel sia una rappresentazione potente, le energie nei banchi di filtri Mel adiacenti sono spesso altamente correlate. Gli MFCC, input per la Pipeline B, spingono questa filosofia un passo avanti, cercando di produrre una rappresentazione ancora più compatta e decorrelata. Dopo aver ottenuto lo spettrogramma Log-Mel, si applica la Trasformata Coseno Discreta (DCT) per decorrelare i coefficienti. Per il nostro modello avanzato, abbiamo impilato gli MFCC con le loro derivate temporali, **Delta** (Δ) e **Delta-Delta** ($\Delta\Delta$), creando un input a 3 canali che cattura esplicitamente la dinamica del suono. Questo tensore non solo descrive la forma dello spettro in ogni istante, ma cattura esplicitamente la sua evoluzione dinamica, un'informazione cruciale per distinguere suoni simili ma con andamenti temporali diversi (es. un suono stazionario da uno pulsato).

2.3.3 Vettore di Feature Ingegnerizzate (Pipeline C)

In contrasto con gli approcci *data-driven* delle Pipeline A e B, la Pipeline C incarna una filosofia più tradizionale basata sull'ingegnerizzazione manuale delle feature (*feature engineering*). L'obiettivo era creare un vettore monodimensionale che catturasse diverse proprietà acustiche del segnale, da fornire poi in input a una CNN 1D, adatta a processare serie temporali multivariate. Le feature estratte per ogni clip audio sono:

- **Chromagram:** Misura la distribuzione dell'energia spettrale attraverso le 12 classi di pitch cromatiche. È particolarmente utile per catturare le caratteristiche armoniche e melodiche del suono.
- **Spectral Contrast:** Calcola la differenza di ampiezza tra i picchi e le valli dello spettro. Questa feature aiuta a distinguere suoni con una struttura tonale chiara da suoni più rumorosi o testurizzati.
- **Spectral Centroid:** Rappresenta il "centro di massa" dello spettro, indicando dove si concentra la maggior parte dell'energia. È un indicatore della "brillantezza" di un suono.
- **Spectral Rolloff:** È la frequenza al di sotto della quale si trova una specificata percentuale (es. 85%) dell'energia spettrale totale. Fornisce un'altra misura della forma dello spettro.
- **Zero Crossing Rate (ZCR):** Indica la frequenza con cui il segnale audio attraversa l'asse dello zero. Valori elevati sono spesso associati a suoni rumorosi o percussivi.

Assemblaggio del Vettore di Input. La sfida principale consisteva nel combinare queste feature, che hanno dimensionalità diverse. Chromagram e Spectral Contrast sono matrici 2D (con shape *feature* $\times$ *timesteps*), mentre le altre sono vettori 1D (con shape $1 \times$ *timesteps*). Per creare un input coerente per la CNN 1D, abbiamo eseguito i seguenti passaggi:

1. Le feature 1D sono state espanse per avere una dimensione "feature" pari a 1.
2. Tutte le feature (le matrici 2D originali e i vettori 1D espansi) sono state concatenate lungo l'asse delle feature.
3. La matrice risultante è stata trasposta per ottenere un formato finale di (*timesteps*, *features*).

Questo processo ha prodotto una serie temporale multivariata, dove per ogni timestep si ha un vettore che descrive le diverse proprietà acustiche del segnale in quell'istante, preservando la sequenzialità temporale per l'analisi da parte della CNN 1D.

2.4 Architetture Sperimentali e Modello Avanzato

Il nostro percorso è partito da tre pipeline parallele per poi convergere su un'architettura ibrida.

Architetture Ibride CNN-RNN. L'ispirazione per combinare CNN e RNN deriva da lavori consolidati nel campo, come quelli di Spoorthy et al. [6] e dalla tesi di Wang [2], che evidenziano come le CNN eccellano nell'estrarre feature locali tempo-frequenza, mentre le RNN modellano le dipendenze temporali a lungo termine.

2.4.1 Blocco Ricorrente: Gated Recurrent Unit (GRU)

A valle della CNN, abbiamo inserito due layer di GRU bidirezionali [2]. Una GRU controlla il flusso di informazioni tramite un **gate di aggiornamento** (z_t) e un **gate di reset** (r_t):

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad (2)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t]) \quad (3)$$

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t]) \quad (4)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (5)$$

L'uso di GRU bidirezionali permette al modello di processare la sequenza in entrambe le direzioni, catturando un contesto più ricco.

2.4.2 Funzione di Costo: Focal Loss

Per affrontare lo sbilanciamento delle classi e concentrare l'addestramento sugli esempi "difficili", abbiamo usato la Focal Loss [3]:

$$\text{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (6)$$

dove il parametro **focalizzante** γ riduce il peso dei campioni facili, mentre α_t bilancia l'importanza delle classi. Abbiamo usato $\gamma = 1.5$ e $\alpha = 0.25$.

3 Risultati e Discussione

Il nostro processo di addestramento ha seguito una struttura standardizzata per ogni pipeline, basata sulla suddivisione in fold del dataset. I dati pre-calcolati sono stati caricati, e il modello è stato addestrato e valutato.

3.1 Fase 1: Confronto delle Pipeline Iniziali

Un primo ciclo di addestramento (10 epoche), a seguito anche di un confronto mediante la tecnica della cross-validation per ogni pipeline, ha rivelato una chiara gerarchia di performance (Tabella 1).

Tabella 1: Performance preliminari delle pipeline iniziali.

Pipeline	Feature di Input	Accuracy
A (2D-CNN)	Log-Mel Spectrogram	$\approx 61\%$
B (2D-CNN)	MFCC	$\approx 65\%$
C (1D-CNN)	Vettore Ingegnerizzato	$\approx 40\%$

Il divario di oltre 20 punti percentuali tra gli approcci data-driven (A, B) e quello basato su feature ingegnerizzate (C) ha confermato la nostra ipotesi: permettere alla rete di apprendere autonomamente le feature da una rappresentazione ricca è una strategia vincente.

3.2 Fase 2: Ottimizzazione Iterativa e Modello Finale

I risultati della Fase 1 hanno indicato in modo inequivocabile la superiorità degli approcci data-driven, con la Pipeline B (basata su MFCC) che emergeva come la più promettente. La seconda fase del nostro lavoro è stata quindi dedicata a un'evoluzione metodologica di questa pipeline, trasformandola da un modello di base a un'architettura avanzata attraverso un processo di analisi, ipotesi e validazione.

3.2.1 Impatto dell'Architettura Ottimizzata sulle Pipeline Originali

Prima di procedere con l'evoluzione specifica della Pipeline B, un passo cruciale è stato validare l'efficacia della nuova architettura di base (ibrida 1D/2D-CNN + 2 Bi-GRU, addestrata con Focal Loss) riaddestrando le tre pipeline originali, aumentando anche le epoche da 10 a 100. L'obiettivo era capire se i miglioramenti fossero legati solo alle feature o se l'architettura stessa giocasse un ruolo determinante. I risultati, riassunti in Tabella 2, sono stati illuminanti.

Tabella 2: Performance delle pipeline riaddestrate.

Pipeline	F1-Score (Weighted)	Accuracy
A (Log-Mel)	0.84	84.04%
B (MFCC)	0.83	83.31%
C (Vector)	0.75	74.75%

Tabella 3: Valori di Loss delle pipeline.

Pipeline	Loss
A (Log-Mel)	0.0996
B (MFCC)	0.0917
C (Vector)	0.0875

Questo esperimento ha rivelato che le pipeline A e B hanno mostrato un balzo prestazionale notevole, passando da un'accuracy preliminare del 61-65% a oltre l'83-84%. Questo dimostra che gran parte del miglioramento era attribuibile alla robustezza dell'architettura ibrida e alla funzione di costo Focal Loss, non solo alla scelta delle feature.

Questi risultati hanno solidificato la nostra decisione di concentrare l'ottimizzazione finale (l'introduzione dei Delta e di SpecAugment) sulla pipeline che offriva il miglior connubio tra ricchezza delle feature e performance di base: la Pipeline B.

3.2.2 Sviluppo della Pipeline B-Advanced: un Approccio a Tre Pilastri

L'obiettivo era superare le limitazioni di un modello base e affrontare le confusioni sistematiche tra classi acusticamente simili. Abbiamo strutturato lo sviluppo della **Pipeline B-Advanced** su tre pilastri fondamentali:

- 1. Arricchimento delle Feature di Input:** L'analisi qualitativa dei primi errori ha rivelato che il modello faticava a distinguere suoni con texture spettrali simili ma dinamiche temporali diverse (es. il ronzio stazionario di un **air_conditioner** rispetto a quello più variabile di un **engine_idling**). Per fornire al modello questa informazione cruciale, abbiamo sostituito l'input MFCC a singolo canale con un tensore a 3 canali, impilando gli MFCC statici con le loro derivate temporali (Delta e Delta-Delta).
- 2. Potenziamento dell'Architettura Ricorrente:** Ispirandoci alla letteratura [2], abbiamo ipotizzato che una gerarchia di apprendimento temporale più profonda potesse catturare meglio le sequenze complesse. Abbiamo quindi sostituito il singolo layer Bi-GRU con una struttura di layer impilati, per permettere al modello di apprendere feature temporali a diversi livelli di astrazione. Per mitigare il conseguente rischio di overfitting, abbiamo inserito layer di Dropout tra i blocchi GRU.

3. **Ottimizzazione della Funzione di Costo:** Abbiamo adottato la Focal Loss per forzare il modello a concentrarsi sui campioni più difficili e a risolvere le confusioni sistematiche tra classi acusticamente simili, dando meno peso agli errori su esempi "facili" e già appresi.

3.2.3 Analisi del Modello con 3 Layer GRU: un Successo con Effetti Collaterali

La prima implementazione della Pipeline B-Advanced, dotata di **3 layer Bi-GRU**, ha prodotto un'accuracy sul test set dell'**84.87%**. Sebbene questo valore fosse marginalmente inferiore a quello ottenuto da un modello base addestrato per più epoche (86.37%), un'analisi qualitativa della matrice di confusione ha rivelato un cambiamento fondamentale e ambivalente:

- **Successo Mirato:** La confusione critica tra i suoni stazionari `engine_idling` e `air_conditioner` era stata quasi completamente risolta. Questo ha validato la nostra ipotesi: le feature dinamiche e l'architettura ricorrente profonda erano state efficaci nel discriminare suoni sulla base della loro evoluzione temporale.
- **Nuova Criticità (Overfitting Ritmico):** Era emersa una nuova e significativa confusione tra i suoni percussivi `drilling` e `jackhammer`. La precisione del modello per la classe `jackhammer` era crollata ad un inaccettabile **65%**. La nostra ipotesi era che il modello a 3 GRU, diventando estremamente sensibile ai pattern temporali, avesse **sovra-specializzato** il suo apprendimento sui ritmi marcati, generalizzando eccessivamente il pattern del martello pneumatico e applicandolo erroneamente anche ai suoni del trapano.

3.2.4 Il "Sweet Spot": Ottimizzazione a 2 Layer GRU

Il problema emerso non era di performance pura, ma di equilibrio e robustezza. Per risolverlo, abbiamo condotto un esperimento di ottimizzazione mirato, riducendo la complessità del modello per contrastare la sovra-specializzazione ritmica. La componente ricorrente è stata semplificata a **2 layer Bi-GRU**.

Il modello risultante ha ottenuto un'accuracy del **84.93%**, virtualmente identica al precedente, ma con un comportamento di classificazione notevolmente più equilibrato, come rivelato dall'analisi:

- La confusione tra `drilling` e `jackhammer` è stata significativamente ridotta, con la precisione per `jackhammer` che è risalita a un più robusto **73%**.
- La confusione tra `engine_idling` e `air_conditioner` è leggermente riaumentata, evidenziando un chiaro **trade-off** architetturale tra la capacità di distinguere suoni stazionari e quella di distinguere suoni percussivi.

Questo modello a 2 GRU rappresentava il miglior compromesso raggiungibile tramite la sola ottimizzazione architetturale: un "sweet spot" che bilanciava complessità e capacità di generalizzazione.

3.2.5 L'Impatto Decisivo di SpecAugment: Superare il Plateau Finale

Avendo identificato l'architettura di base ottimale, abbiamo affrontato le residue criticità con una tecnica di data augmentation stato-dell'arte, **SpecAugment**, integrata direttamente nel modello. L'obiettivo era forzare il modello a imparare rappresentazioni più olistiche e meno dipendenti da specifiche caratteristiche locali, sia spettrali che temporali, risolvendo così il trade-off osservato.

L'introduzione di SpecAugment ha prodotto il salto di qualità definitivo, portando l'accuracy finale sul test set all'**87.0%** (Loss **0.0743**). Questo risultato non solo ha superato l'obiettivo prefissato, ma, come evidenziato dal report di classificazione dettagliato (Tabella 4), ha dimostrato la risoluzione delle criticità precedenti. L'analisi comparativa dei punteggi F1-score evidenzia il successo della strategia:

- L'F1-score della classe `drilling`, il punto debole del modello precedente, è salito a un solido **0.78**.
- Le performance su tutte le altre classi critiche, come `jackhammer` e la coppia `engine_idling/air_conditioner`, sono anch'esse migliorate, portando a un modello complessivamente più affidabile ed equilibrato.

La matrice di confusione (Figura 1) conferma visivamente questo successo, mostrando una diagonale più forte e una minore dispersione di errori tra le classi. Il progetto aveva così dimostrato che la combinazione di una ricca rappresentazione del segnale, un'architettura ibrida attentamente bilanciata e tecniche di augmentation avanzate costituisce una strategia vincente per questo complesso task.

Tabella 4: Report di classificazione del modello finale ottimizzato.

Classe	Precision	Recall	F1-Score	Support
<code>air_conditioner</code>	0.75	0.89	0.81	196
<code>car_horn</code>	0.96	0.92	0.94	159
<code>children_playing</code>	0.82	0.81	0.82	182
<code>dog_bark</code>	0.87	0.89	0.88	159
<code>drilling</code>	0.78	0.78	0.78	169
<code>engine_idling</code>	0.96	0.79	0.87	225
<code>gun_shot</code>	0.94	0.99	0.96	237
<code>jackhammer</code>	0.91	0.86	0.88	174
<code>siren</code>	0.87	0.93	0.90	155
<code>street_music</code>	0.84	0.80	0.82	142
Accuracy		0.870		1798
Weighted Avg	0.87	0.87	0.87	1798




Figura 1: Matrice di confusione normalizzata del modello finale sul test set

3.3 Fase 3: La Prova dell'Ensemble – Specializzazione vs. Competizione

Dopo aver ottimizzato il nostro modello multiclasse fino a raggiungere un'accuracy dell'87.0%, l'ultima fase del progetto è stata dedicata a esplorare una domanda fondamentale: un "comitato di specialisti" (un'architettura ensemble) può superare le performance di un singolo classificatore "generalista"? L'approccio scelto è stato quello **One-vs-Rest (OvR)**, addestrando 10 classificatori binari, ciascuno dedicato a riconoscere una singola classe contro tutte le altre.

3.3.1 Esperimento 1: Ensemble Semplice One-vs-Rest (OvR)

Il primo esperimento ha previsto l'addestramento di 10 modelli binari, basati sulla nostra architettura ottimizzata (2D-CNN + 2 Bi-GRU + SpecAugment), ma con un output sigmoide e una binary focal loss. La decisione finale dell'ensemble è stata presa tramite un meccanismo di *winner-takes-all*, selezionando la classe il cui classificatore ha fornito la probabilità più alta (argmax).

I risultati, tuttavia, sono stati controintuitivi. L'ensemble OvR ha raggiunto un'accuracy complessiva dell'**81.8%**, un valore significativamente inferiore a quello del modello multiclasse. L'analisi ha rivelato che, sebbene ogni classificatore binario raggiungesse un'elevata accuracy nel suo compito isolato (spesso >94%), questa metrica era ingannevole. L'alta performance derivava principalmente dalla capacità di classificare correttamente l'enorme maggioranza di campioni negativi "facili", ma non rifletteva una reale capacità di discriminazione tra classi acusticamente simili. Il sistema soffriva di una **perdita di contesto competitivo**: ogni modello imparava a riconoscere la propria classe in isolamento, senza mai apprendere a distinguerla esplicitamente dalle sue "rivali" più prossime.

3.3.2 Esperimento 2: Ensemble Ibrido Eterogeneo a Cascata

Sulla base di queste scoperte, abbiamo progettato un secondo, più sofisticato, esperimento per mitigare i punti deboli dell'approccio OvR. L'ipotesi era di creare un **ensemble eterogeneo** combinato con una logica a cascata per i casi di incertezza.

- **Specializzazione dell'Architettura:** Basandoci sulle analisi dei modelli precedenti, per le classi stazionarie e temporalmente complesse (**engine_idling**, **air_conditioner**) sono stati impiegati classificatori binari con una rete ricorrente più profonda a 3 layer Bi-GRU. Per tutte le altre classi, è stata mantenuta l'architettura più bilanciata a 2 layer Bi-GRU.

- **Logica a Cascata:** Per i campioni su cui l'ensemble OvR mostrava incertezza (definiti come i casi in cui più di un classificatore binario restituiva una probabilità superiore a una soglia dell'80%), la decisione finale veniva delegata al nostro miglior modello multiclasse, che agiva da "esperto" risolutore di ambiguità.

Questo sistema ibrido avanzato ha ottenuto un'accuracy finale dell'**83.15%**. Sebbene rappresenti un miglioramento misurabile rispetto all'ensemble OvR di base, non è riuscito a eguagliare le performance del modello multiclasse singolo. L'analisi ha rivelato che la logica a cascata è stata attivata solo per un numero esiguo di campioni (1.72% del test set), indicando che i classificatori binari, pur essendo spesso in errore, tendono a produrre punteggi di probabilità che raramente superano la soglia di incertezza in modo competitivo. Il report di classificazione dettagliato (Tabella 5) e la matrice di confusione (Figura 3) confermano i limiti intrinseci dell'approccio. Nonostante l'uso di un modello a 3 GRU, la confusione tra **engine_idling** e **air_conditioner** (32 errori) è rimasta significativa, e la precision per la classe **jackhammer** è scesa al 68%.

Tabella 5: Report di classificazione dell'Ensemble Ibrido.

Classe	Precision	Recall	F1-Score	Support
air_conditioner	0.73	0.79	0.76	196
car_horn	0.96	0.90	0.93	159
children_playing	0.78	0.81	0.79	182
dog_bark	0.89	0.89	0.89	159
drilling	0.71	0.79	0.75	169
engine_idling	0.95	0.73	0.83	225
gun_shot	0.97	0.98	0.98	237
jackhammer	0.68	0.89	0.77	174
siren	0.86	0.85	0.86	155
street_music	0.83	0.64	0.73	142
Accuracy		0.8315		1798
Weighted Avg	0.84	0.83	0.83	1798




Figura 2: OvR diagram

3.3.3 Conclusione sulla Strategia di Modellazione

Il percorso di ricerca, culminato negli esperimenti con architetture ensemble, converge verso una conclusione fondamentale: per il task di classificazione di suoni urbani, un modello multiclasse end-to-end è intrinsecamente superiore a un insieme di specialisti binari. La capacità di un modello di apprendere in un contesto competitivo, dove la funzione di costo Soft-max forza una decisione relativa tra tutte le classi, è più efficace della specializzazione isolata. Il modello singolo impara a risolvere le ambiguità, mentre l'ensemble tende a perpetuarle.




Figura 3: Matrice di confusione dell'ensemble ibrido. L'accuracy complessiva è dell'83.15%.

4 Conclusioni

Questo progetto ha condotto un'esplorazione metodologica sulla classificazione di suoni urbani, portando a conclusioni tanto tecniche quanto concettuali.

1. **La rappresentazione è cruciale:** Gli approcci data-driven che utilizzano rappresentazioni ricche del segnale (MFCC, Log-Mel) sono intrinsecamente superiori all'ingegnerizzazione manuale di feature per questo task.
2. **La dinamica distingue:** L'aggiunta di feature dinamiche (Delta e Delta-Delta) è stata fondamentale per risolvere ambiguità tra suoni con texture spettrali simili ma evoluzioni temporali diverse.
3. **L'augmentation robustifica:** L'integrazione di SpecAugment si è rivelata la mossa decisiva per superare un plateau di performance, migliorando la generalizzazione del modello in modo significativo.
4. **La competizione vince sulla specializzazione:** La nostra scoperta più significativa è che, per un task con un'alta sovrapposizione acustica tra le classi, un modello multiclasse end-to-end è superiore a un insieme di specialisti binari. La necessità di un apprendimento competitivo, imposto dalla funzione Softmax, è più efficace della specializzazione isolata.

In definitiva, il nostro studio identifica in un singolo modello ibrido (2D-CNN + 2 Bi-GRU), alimentato da MFCC arricchiti con le loro derivate e regolarizzato da SpecAugment, la soluzione ottimale. L'accuracy raggiunta dell'87.0% non è solo un eccellente risultato tecnico, ma la validazione di un approccio metodologico che privilegia l'analisi iterativa, l'ottimizzazione mirata e una profonda comprensione dei meccanismi di apprendimento del modello.

Riferimenti bibliografici

- [1] Augustin Arnault, Baptiste Hanssens, and Nicolas Riche. [Urban sound classification: striving towards a fair comparison](#). *arXiv preprint arXiv:2010.11805*, 2020.
- [2] Yun Wang. [Polyphonic Sound Event Detection with Weak Labeling](#). *PhD thesis, Language Technologies Institute, Carnegie Mellon University*, 2018.
- [3] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. [Focal loss for dense object detection](#). In *Proceedings of the IEEE international conference on computer vision*, 2017.
- [4] Daniel S. Park, William Chan, Yu Zhang, Chung-Cheng Chiu, Barret Zoph, Ekin D. Cubuk, and Quoc V. Le. [SpecAugment: A simple data augmentation method for automatic speech recognition](#). In *Proc. Interspeech 2019*, 2019.
- [5] Karol J. Piczak. [Environmental Sound Classification with Convolutional Neural Networks](#). In *2015 IEEE International Workshop on Machine Learning for Signal Processing (MLSP)*, pages 1–6, 2015.
- [6] V. Spoorthy, Manjunath Mulimani, and Shashidhar G. Koolagudi. [Acoustic scene classification using deep learning architectures](#). In *2021 6th International Conference for Convergence in Technology (I2CT)*, 2021.
- [7] Finley Walden, Sagar Dasgupta, Mizanur Rahman, and Mhafuzul Islam. [Improving the Environmental Perception of Autonomous Vehicles using Deep Learning-based Audio Classification](#). *arXiv preprint arXiv:2209.04075*, 2022.